

综合应用题

本套真题电子版，已适配 2025 年 9 月考试！

祝考试顺利！

关注微博：大头博士先生，考完押题

关注 B 站：大头博士先生，考前直播带刷特殊做法！

【第 1 套题】

1、考生文件夹下存在 2 个 Python 源文件，分别对应以下 2 个问题，请修改代码，实现以下功能：

以下数据采集自一套公司职员随身佩戴的位置传感器，该数据文件名称为“sensor.txt”，其内容示例如下：

```
2016/5/31 0:05, vawelon001,1,1
2016/5/31 0:20, earpa001,1,1
2016/5/31 2:26, earpa001,1,6
...(略)
```

此数据中，各列之间由逗号分隔，第一列是传感器获取数据的时间，第二列是传感器的编号，第三列是传感器所在的楼层，第四列是传感器所在的位置区域编号。

问题 1 (10 分)：数据处理。要求：在 PY301-1.py 文件中修改代码，读入 sensor.txt 文件中的数据，提取传感器编号为 earpa001 的所有数据，将结果输出保存到“earpa001.txt”文件。输出文件格式要求：原数据文件中的每行记录写入新文件中，行尾无空格，无空行。参考格式如下：

```
2016/5/31 7:11, earpa001,2,4
2016/5/31 8:02, earpa001,3,4
2016/5/31 9:22, earpa001,3,4
...(略)
```

问题 2 (10 分)：数据统计。要求：在 PY301-2.py 文件中修改代码，读入“earpa001.txt”文件中的数据，统计 earpa001 对应职员在各楼层和区域出现的次数，保存到“earpa001_count.txt”文件，每条记录一行，楼层和区域之间用横线分割，位置信息和出现次数之间用英文半角逗号隔开，行尾无空格，无空行。参考格式如下。

```
1-1,5
1-4,3
...(略)
```

含义如下：

第 1 行 “1-1,5” 中 1-1 表示 1 楼 1 号区域，5 表示出现 5 次；

第 2 行 “1-4,3” 中 1-4 表示 1 楼 4 号区域，3 表示出现 3 次；

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。



【第 2 套题】

2、考生文件夹下存在 2 个 Python 源文件和 3 个文本文件，分别对应两个问题，请按照文件内说明修改代码，实现以下功能：

《论语》是儒家学派的经典著作之一，主要记录了孔子及其弟子言行。这里给出了一个网络版本的《论语》，文件名称为“论语.txt”，其内容采用逐句“原文”与逐句“注释”相结合的形式组织，通过【原文】标记《论语》原文内容，通过【注释】标记《论语》注释内容，具体文件格式框架请参考“论语.txt”文件。

问题 1 (10 分)：提取文件指定内容。要求：在 PY301-1.py 文件中修改代码，提取“论语.txt”文件中的原文内容，输出保存到考生文件夹下，文件名为“论语-原文.txt”。具体要求：仅保留“论语.txt”文件中所有【原文】标签下面的内容，不保留标签，并去掉每行行首空格及行尾空格，无空行。原文小括号及内部数字是源文件中注释项的标记，请保留。示例输出文件格式请参考“论语-原文-输出示例.txt”文件。（注意：示例输出文件仅帮助考生了解输出格式，不作它用。）

问题 2 (10 分)：清洗提取出的文件内容。要求：在 PY301-2.py 文件中修改代码，对“论语-原文.txt”或“论语.txt”文件进一步提纯，去掉每行文字中所有小括号及内部数字，保存为“论语-提纯原文.txt”文件。示例输出文件格式请参考“论语-提纯原文-输出示例.txt”文件。（注意：示例输出文件仅帮助考生了解输出格式，不作它用。）

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 3 套题】

3、考生文件夹下存在 3 个 Python 源文件, 分别对应 3 个问题, 请按照文件内说明修改代码, 实现以下功能:

二千多年前希腊的天文学家希巴克斯命名十二星座, 它们是水瓶座、双鱼座、白羊座、金牛座、双子座、巨蟹座、狮子座、处女座、天秤座、天蝎座、射手座、魔蝎座。给出一个 CSV 文件 (PY301-SunSign.csv), 内容示例如下:

序号,星座,开始月日,结束月日,Unicode

1,水瓶座,120,218,9810

2,双鱼座,219,320,9811

3,白羊座,321,419,9800

4,金牛座,420,520,9801

5,双子座,521,621,9802

...(略)

以第 1 行为例, 120 表示 1 月 20 日, 218 表示 2 月 18 日, 9810 是 Unicode 码。

问题 1 (5 分): 根据星座名称查询出生日期范围。要求: 在 PY301-1.py 文件中修改代码, 读入 CSV 文件中数据, 获得用户输入。根据用户输入的星座名称, 输出此星座的出生日期范围。

参考输入和输出示例格式如下:

请输入星座中文名称(例如, 双子座):双子座

双子座的生日位于 521-621 之间

问题 2 (10 分): 根据星座序号查询星座信息。在 PY301-2.py 文件中修改代码, 读入 CSV 文件中数据, 获得用户输入。用户键盘输入一组范围是 1-12 的整数作为序号, 序号间采用空格分隔, 以回车结束。屏幕输出这些序号对应的星座的名称、字符编码以及出生日期范围, 每个星座的信息一行。本次屏幕显示完成后, 重新回到输入序号的状态。

参考输入和输出示例格式如下:

请输入星座序号(例如,5):5 10

双子座(9802)的生日是 5 月 21 日至 6 月 21 日之间

天蝎座(9807)的生日是 10 月 24 日至 11 月 22 日之间

请输入星座序号(例如,5):

问题 3 (5 分): 根据星座序号查询星座信息, 并对无效序号的给出错误提示。在问题 2 的基础上, 在 PY301-3.py 文件中修改代码, 对键盘输入的每个序号做合法性处理。如果输入的数字不合法, 请输出"输入星座编号有误!", 继续输出后续信息, 然后重新回到输入序号的状态。

参考输入和输出示例格式如下：

请输入星座序号(例如,5):5 14 11

双子座(9802)的生日是 5 月 21 日至 6 月 21 日之间

输入星座序号有误!

射手座(9808)的生日是 11 月 23 日至 12 月 21 日之间

请输入星座序号(例如,5):

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。



【第 4 套题】

4、考生文件夹下有 4 个文件，其中，3 个 Python 源文件，分别对应以下 3 个问题，1 个文本文件，作为本题目输入数据。

《命运》是著名科幻作家倪匡的作品。考生文件夹中，给出《命运》的一个网络版本文件，文本文件名为“命运.txt”。

请分别按照 3 个源文件内部说明修改代码，实现以下功能：

问题 1 (5 分)：统计最高字符及其频次并输出。要求：在 PY301-1.py 文件中修改代码，对“命运.txt”文件进行字符频次统计，屏幕输出频次最高的中文字符（不包含标点符号）及其频次，字符与频次之间采用英文冒号":"分隔，示例格式如下：

理:224

问题 2 (5 分)：输出前 10 个最高字符及其频次。要求：在 PY301-2.py 文件中修改代码，对“命运.txt”文件进行字符频次统计，按照频次由高到低，屏幕连续输出前 10 个频次最高的字符（字符之间不包含回车符，且字符之间无间隔），示例格式如下：

理斯卫...(后略，共 10 个字符)

问题 3 (10 分)：统计字符频次并将结果输出到新的文本文件中。要求：在 PY301-3.py 文件中修改代码，对“命运.txt”文件进行字符频次统计，将所有字符按照频次从高到低排序，字符包括中文、标点、英文等符号，但不包含空格和回车。将排序后的字符及频次输出到考生文件夹下，文件名为“命运-频次排序.txt”。字符与频次之间采用英文冒号":"分隔，各字符之间采用英文逗号","分隔，参考 CSV 格式，最后无逗号，文件内部示例格式如下：

理:224,斯:120,卫:100

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 5 套题】

5、考生文件夹下，有 3 个文件。其中 2 个 python 源文件分别对应两个问题，1 个文本文件为两个问题的数据文件。

《三国演义》是中国古典四大名著之一，曹操是其中主要人物，在文本文件中，给出了《三国演义》简介。请分别修改 2 个 Python 源文件，按照以下要求，解决以下 2 个问题：

问题 1（10 分）：将文本分词并输出到结果文件中。要求：打开 PY301-1.py，补充代码完成程序。用 Python 语言中文分词第三方库 jieba 对文件 data.txt 进行分词，并将结果写入文件 out.txt 中，要求每行一个词。示例如下：

内容简介

编辑

整个

故事

在

东汉

...

问题 2（10 分）：统计曹操出现次数并打印输出。要求：打开 PY301-2.py，补充其中代码，对问题 1 中输出的文本文件 out.txt 中的结果进行分析，并屏幕打印输出曹操出现的次数。

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 6 套题】

6、考生文件夹下存在 2 个 Python 源文件和 1 个文本文件，分别对应 2 个问题，文件 data.txt 是一个来源于网上的技术信息资料，请按照文件内说明修改代码，实现以下功能。

问题 1 (10 分)：提取关键词。要求：在 PY301-1.py 文件中修改代码，用中文分词第三方库 jieba 对文件 data.txt 进行分词，并选择长度不少于 3 个字符的关键词，写入文件 out1.txt，每行 1 个关键词，各行关键词不重复，对输出顺序不做要求。示例如下：

人工智能
科幻小说
...(略)

问题 2 (10 分)：统计词频按高低顺序输出。要求：在 PY301-2.py 文件中修改代码，对文件 data.txt 进行分词，对长度不少于 3 个字符的关键词，统计出现的次数，按照出现次数由大到小的顺序输出到文件 out2.txt，每行为 1 个关键词及其出现次数，关键词和次数之间用冒号分隔。示例如下：

科学家:2
达特茅斯:1
...(略)

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 7 套题】

7、在考生文件夹下存在 2 个 Python 源文件 PY301-1.py、PY301-2.py 和素材文件 score301.txt。

score301.txt 文件是某班学生评选一等奖学金的 10 门主干课成绩信息。每行一个学生的信息，包含学生学号、姓名以及 10 门课成绩，格式如下：

1820161043 郑珉镐 68 66 83 77 56 73 61 69 66 78

1820161044 沈红伟 91 70 81 91 96 80 78 91 89 94

...(略)

打开 PY301-1.py，编程完成以下功能：

问题 1（10 分）：读取 score301.txt 中的学生成绩数据，计算出每名学生的总成绩，将总成绩从高到低排序。将前 10 名学生信息写入文件 cand301.txt 中。每行记录一名学生的信息，包括学生学号、姓名以及 10 门课的成绩。示例如下：

...(略)

1010112161 张三 100 92 94 88 91 96 59 84 96 64

1010112938 王五 91 70 81 91 96 80 78 91 89 94

...(略)

打开 PY301-2.py，编程完成以下功能：

问题 2（10 分）：读取文件 cand301.txt，在学生中选出一等奖学金候选人，必须满足 2 个条件：1) 总成绩排名在前 10 名；2) 10 门课程的成绩都大于等于 60。

将候选人学号和姓名写入文件 best301.txt。格式示例如下：

1010112161 张三

1010112728 李四

...(略)

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 8 套题】

8、考生文件夹下存在 2 个 Python 源文件和 1 个文本文件。2 个 Python 源文件分别对应 2 个问题, 1 个文本文件 data.txt 是教育部爱课程网中国大学 MOOC 平台的某个 HTML 页面源文件, 包含了我国参与 MOOC 建设的一批大学或机构列表。请分别修改 2 个 Python 源文件, 实现以下功能。

问题 1 (10 分): 数据清洗。要求: 修改 PY301-1.py 文件中代码, 从 data.txt 中提取大学或机构名称列表, 将结果写入文件 univ.txt, 每行一个大学或机构名称, 并按照大学或机构在 data.txt 出现的先后顺序输出, 样例如下:

```
...  
北京理工大学  
...(略)  
北京师范大学  
...
```

提示: 所有大学名称在 data.txt 文件中以 alt="北京理工大学"形式存在。

问题 2 (10 分): 数据统计。要求: 修改 PY301-2.py 文件中代码, 从 univ.txt 文件中进一步筛选, 去掉机构名称, 筛选出大学名称。这里定义: 大学名称均包含“大学”或“学院”字样, 但不包括“大学生”等字样。请将筛选后的大学名称输出在屏幕上, 大学各行之间没有空行, 最后请分别给出包含“大学”和“学院”名称的数量。同时包含“大学”和“学院”的名称当作“大学”处理, 不计为“学院”。样例如下 (样例中数量不是真实结果):

```
...  
北京理工大学  
...(略)  
长沙师范学院  
...
```

```
包含大学的名称数量是 10  
包含学院的名称数量是 10
```

提示: 建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 9 套题】

9、考生文件夹下存在 2 个 Python 源文件和 2 个文本文件。其中，2 个 Python 源文件对应 2 个问题，2 个文本文件分别摘自 2019 年和 2018 年的政府工作报告。请分别补充 2 个 Python 源文件，实现以下功能。

问题 1 (10 分)：数据统计。要求：修改 PY301-1.py 文件中代码，分别统计两个文件中出现次数最多的 10 词语，作为主题词，要求词语不少于 2 个字符，打印输出在屏幕上，输出示例如下：（示例词语非答案）

2019:改革:10,企业:9,...(略),深化:2

2018:改革:11,效益:7,...(略),深化:1

注意：输出格式采用英文冒号和英文逗号，标点符号前后无空格，各词语间用逗号分隔，最后一个词语后无逗号。

问题 2 (10 分)：数据关联。要求：修改 PY301-2.py 文件中代码，对比两组主题词的差异，输出两组的共有词语和分别的特有词语。输出示例如下：（示例词语非答案）

共有词语:改革,...(略),深化

2019 特有:企业,...(略),加强

2018 特有:效益,...(略),创新

注意：输出格式采用英文冒号和英文逗号，标点符号前后无空格，各词语间用逗号分隔，最后一个词语后无逗号。

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 10 套题】

10、在考生文件夹下存在 2 个 Python 源文件 PY301-1.py、PY301-2.py 和素材文件 data.txt。

data.txt 文件包含关于“德国工业 4.0 战略规划实施建议摘要”的内容。

打开 PY301-1.py，编程完成以下功能：

问题 1（10 分）：清理 data.txt 文件里的内容，去除中文标点符号、换行符和中英文空格，只保留中文字符、英文字符、数字、英文标点符号等符号，将结果输出到文件 clean.txt 中。示例如下：

德国工业 4.0 战略计划实施建议摘编机械工业信息研究院战略与规化研究所—德国实施工业…(略)

打开 PY301-2.py，编程完成以下功能：

问题 2（10 分）：提取 clean.txt 文件中长度不少于 3 个字符的词并统计其词频，输出词频最高的 10 个词及其词频。词与词频之间用英文冒号隔开；每个词之间用英文逗号隔开；标点符号前后无空格，最后一个词后无逗号。示例如下：

4.0:10,制造业:9, …(略)

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 11 套题】

11、在考生文件夹下有 2 个文件，一个 Python 源文件 py301.py，以及一个包含了《红楼梦》小说前 20 章内容的文本文件“红楼梦.txt”。请修改 py301.py，针对“红楼梦.txt”文件，实现以下功能。

(1) (5 分) 统计并显示输出, . : ; ? 这 5 种标点符号出现的总个数，格式示例如下（非真实答案）：

1234

(2) (10 分) 对文件进行分词，统计并显示输出长度不小于 2 个字符的词语个数，格式示例如下（非真实答案）：

537

(3) (5 分) 统计并显示输出长度不小于 2 的词语中，出现次数最多的前 2 个词及出现次数，词与出现次数之间用英文逗号分隔，每个词的信息占一行，格式示例如下（非真实答案）：

宝玉, 123

凤姐, 108

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 12 套题】

12、考生文件夹下存在 1 个 Python 源文件 py301.py 和 1 个文本文件“八十天环游地球.txt”。文本文件是法国作家儒勒·凡尔纳《八十天环游地球》长篇小说的网络版本，请修改 py301.py 实现以下功能。

(1) (5 分) 读取该文件里所有文本，显示输出非空文本的行数，格式示例如下（非真实答案）：

共 100 个非空行

(2) (10 分) 将所有文本行里的"? !:,。(一共 6 个符号) 删掉并分词，显示输出剩余的字符数，以及分词后不相同的词语数，格式示例如下（非真实答案）：

剩余字符数 1381，词语数 88

(3) (5 分) 提取“八十天环游地球.txt"中所有章节的标题，并且输出到“八十天环游地球-章节.txt”文件中，每行一个标题，格式示例如下（非真实答案）：

第一章 斐利亚·福克和路路通建立主仆关系
第二章 路路通认为他总算找到了理想的工作
... (略)

提示：建议使用本机提供的 Python 集成开发环境 IDLE 编写、调试及验证程序。

【第 13 套题】

13、在考生文件夹下存在 1 个 Python 源文件 PY301.py 和 1 个素材文件 data301.txt。

data301.txt 文件的每行是一个学生的相关信息，包括姓名、班级和分数。姓名和其他信息之间用英文冒号隔开，班级和分数之间用英文逗号隔开，班级由“系名+班级序号”组成，如“计算 191”。示例如下：

王一:计算 191,340

张二:经济 191,450

… (略)

编程实现如下功能：

(1) (5 分) 统计并显示输出学生人数，格式示例如下（非真实效据）：

素材文件中学生的人数是 256

(2) (10 分) 计算并显示输出所有学生的平均分，小数点后保留 1 位数，格式示例如下（非真实数据）：

所有学生的平均分是 453.2

(3) (5 分) 将学生信息按分数降序排序，输出到 result301.txt 文件。每行一个学生信息，姓名和分数以英文逗号隔开，格式示例如下（非真实数据）：

冯剑健, 549

赵康剑, 541

赵一一, 301

… (略)

提示：建议使用本机提供的 Python 集成开发环境 IDLE 填写，调试及验证程序。

【第 14 套题】

14、在考生文件夹下存在 1 个 Python 源文件 py301.py 和 1 个素材文件 data301.txt。

data301.txt 文件中保存了某网站一个网页的 HTML 格式源代码。在该文件中，JPG 图片以一个完整的 URL 表示，示例如下：

```
<a href="/photography/picture_story/6088.html">  
img src="http://image.ngchina.com.cn/2019/538.JPG"/>  
</a>
```

其中，<a>与是一对组合，表示包含一个 URL 链接；表示包含一个 JPG 图像文件的 URL，每个 URL 用 src=开头，以 JPG 图像文件名结束，如 538.JPG 表示 JPG 图像文件。

打开 py301.py，利用给出的部分代码，编程实现如下功能：

(1) (5 分) 统计并显示输出该页面中<a>标签的个数（以<a 开头），格式示例如下（非真实答案）：

88

(2) (10 分) 统计并显示输出该页面中 JPG 图像文件的 URL 数量。注意，JPG 扩展名都是大写字母，格式示例如下（非真实答案）：

15

(3) (5 分) 将 data301.txt 页面中的 JPG 图像文件的 URL 提取出来，保存在文件 images.txt 中，每个 URL 一行。格式示例如下（非真实答案）：

```
http://image.ngchina.com.cn/2018/0829/20180829012548753.JPG  
http://image.ngchina.com.cn/2018/0823/thumb_469_352_20180823121155508.JPG  
... (略)
```

提示：建议使用本机提供的 Python 集成开发环境 IDLE 填写，调试及验证程序。

【第 15 套题】

15、在考生文件夹下存在 1 个 Python 源文件 py301.py 和 1 个素材文件 data301.txt。

data301.txt 文件内容示例如下：

商业模式价值链由三个环节组成：产品、工具、社区。我们团队以一站式系统开发为当前主要产品，利用 XAMPP，PHPSTORM，微信开发者工具等软件根据客户要求提供合适的一体化管理系统。

…（略）

打开 py301.py，编程实现如下功能：

(1) (5 分) 统计并显示输出 data301.txt 中所有字符的个数，格式示例如下（非真实数据）：

素材文件字符个数是 800。

(2) (10 分) 统计并显示输出 data301.txt 中长度大于 1 且不相同的词个数（排除“我们”“同时”“之后”“更好”“这些”“进行”这 6 个词），并显示输出词频最大的词，格式示例如下（非真实数据）：

长度大于 1 且不相同的词个数是 300。

词频最大的词是：模式

(3) (5 分) 以中文句号作为分隔符，将 data301.txt 文件中的内容切分成句子，将长度大于 1 并且词频最大的词所在的句子（排除“我们”“同时”“之后”“更好”“这些”“进行”这 6 个词），输出到结果文件 out301.txt 中，每句一行，格式示例如下（非真实数据）：

商业模式价值链由三个环节组成：产品、工具、社区

第三是以 B2B 的电商模式建立销售平台

…（略）

提示：建议使用本机提供的 Python 集成开发环境 IDLE 填写，调试及验证程序。

【第 16 套题】

16、在考生文件夹下存在 1 个 Python 源文件 py301.py 和 1 个素材文件 data301.txt。data301.txt 文件是 2020 年 5 月 2 日的一个 HTML 页面源文件, 里面包含了若干个国家的某流行病确诊人数统计数据, 包含国家名称及人数。

格式如下所示 (其中数据仅用于示意):

... (略)

```
{  
"name": "Montserrat",  
"value": 0  
},  
{  
"name": "Saint Helena",  
"value": 0  
},  
{  
"name": "Falkland Islands",  
"value": 0  
},  
... (略)
```

打开 py301.py, 利用给定的现有代码, 编程实现下面功能:

(1) (5 分) 从 data301.txt 中提取国家名称及流行病确诊人数, 显示输出国家的总数。格式示例如下 (非真实答案):

一共有 1000 个国家

(2) (10 分) 对确诊人数进行排序, 显示输出确诊人数最多的国家名称和人数。格式示例如下 (非真实答案):

确诊人数最多的国家是 United States, 人数是 1900000

(3) (5 分) 统计并显示输出确诊人数超过 1W 的国家个数、确诊人数为 0 的国家个数。格式示例如下 (非真实答案):

确诊人数超过 1W 的国家有 20 个

确诊人数为 0 的国家有 40 个

提示: 建议使用本机提供的 Python 集成开发环境 IDLE 填写, 调试及验证程序。

【第 17 套题】

17、在考生文件夹下存在 1 个 Python 源文件 py301.py 和 1 个数据文件 data301.csv。在文件 data301.csv 里，第一行是标题，包括省区、疑似、重症、治愈 4 列；第二行起是各省区某传染病的模拟数据，

每行是一个省区的一组数据信息，代表疑似人数、重症人数、治愈人数。打开 py301.py 文件，编程实现如下功能：

(1) (5 分)：显示部分数据。读取 data301.csv 文件的前 5 行的信息（包含标题行）并显示输出；标题行为“省区，疑似，重症，治愈”，每个省区的数据写一行，数据之间用英文逗号分隔，格式示例如下（非真实数据）：

```
省区，疑似，重症，治愈
香港，2505,18,1455
... (略)
```

(2) (10 分)：统计并保存结果。统计并显示输出所有省区的疑似，重症，治愈人数的总数及取大值；其中标题行为“统计，疑似，重症，治愈”，总数、最大值数据分别写一行，行内数据之间用英文逗号分隔，格式示例如下（非真实数据）：

```
统计，疑似，重症，治愈
总数，156,20,136
最大值，3500,400,3100
```

(3) (5 分)：统计疑似人数超过所有省区平均值的省区名称，省区排序按照该省区的疑似人数降序排序，各省区名称之间用英文半角逗号分隔，格式示例如下（非真实数据）：

```
四川，山东，...，广东，湖南
```

提示：建议使用本机提供的 Python 集成开发环境 IDLE 填写，调试及验证程序。

【第 18 套题】

18、在考生文件夹下存在一个 Python 源文件 py301.py，请编写代码替换横线，可修改其他代码，实现下面功能：

附件文件 data301.txt 是新书《规模》的书评文章，去除换行符后形成了一个连续字符串，里面包含了中文及中文字符，文件内容示例如下：

世间万物既有其存在与发展的内在逻辑，也有其相联、相通的外在逻辑。21 世纪科学所面临的一个重大挑战是，. (略)

(1) (5 分)：请编写程序，统计 data301.txt 中",。? !: "五种符号出现的次数，输出到屏幕上。示例如下（其中数据仅用于示意）：

", "的个数为 100 个
"。"的个数为 101 个
"? "的个数为 105 个
"! "的个数为 99 个
": "的个数为 35 个

(2) (10 分)：对 data301.txt 中的字符串分词，统计词语长度等于 2、3、4、5 的词语的个数，分别将每种词语长度的词语总数输出显示在屏幕上。示例如下（其中数据仅用于示意）：

2 字词有 40 个
3 字词有 27 个
4 字词有 22 个
5 字词有 20 个

(3) (5 分)：在上一问题的程序基础上，将词语长度等于 2、3、4、5 的词语中分别出现次数最多的词语输出，每种词语长度的词构成一行，示例如下（其中数据仅用于示意）：

世间
复杂性
推而广之
10000

提示：建议使用本机提供的 Python 集成开发环境 IDLE 填写，调试及验证程序。

【第 19 套题】

19、在考生文件夹下存在一个 Python 源文件 py301.py，请写代码替换横线，可修改其他代码，实现下面功能：

在文件 data301.txt 里有一些聊天记录，每行对应一个人的发言，英文冒号前面是发言人的名字，冒号后面是发言的内容，由中文字符组成。

文件内容示例如下：

alice：与此同时它们需要建立起烦琐的行政机构和管理组织

bill：规模经济和亚线性规模缩放下的创新思想最终导致了公司的停滞与衰亡

…（略）

编写程序统计聊天记录中出现的词语情况。具体要求如下：

(1) (5 分) 读取该文件里所有行文本，显示输出非空文本的行数，格式示例如下（非真实答案）：

共 100 个非空行。

(2) (10 分) 统计发言的人数，显示输出发言人数及每个人的名字，格式示例如下（非真实答案）：

共 2 个人发言：bill, jone

(3) (5 分) 将同一个人的发言合并成一个字符串，将字符串分词，统计并显示输出：发言人的名字、词语长度大于 1 的词语个数，以及出现次数最多的词语，中间用中文符号隔开，格式示例如下（非真实答案）：

bill 说了 30 个词，最多的词是：规模

jone 说了 15 个词，最多的词是：肌肉

…（略）

提示：建议使用本机提供的 Python 集成开发环境 IDLE 填写，调试及验证程序。